

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN MÔN HỌC MÁY
Phase 1: Scikit-learn

Sinh viên thực hiện:

Nguyễn Bá Duy - 22120071

Phan Bá Đức - 22120078

Đặng Duy Lâm - 22120182

Giảng viên hướng dẫn:

TS. Bùi Duy Đăng

ThS. Nguyễn Thanh Tình

TP. Hồ Chí Minh, tháng 5 năm 2025.

Mục lục

Mục lục.....	1
1. Tổng quan.....	2
1.1. Tóm tắt bài toán.....	2
1.2. Ý tưởng giải quyết.....	3
1.2.1. Tiền xử lý.....	3
1.2.2. Xây dựng mô hình và đánh giá.....	3
2. Tiền xử lý dữ liệu.....	3
3. Huấn luyện mô hình.....	4
4. Đánh giá mô hình.....	5
4.1. Ma trận nhầm lẫn trên tập validation.....	6
4.2. Phân bố các chỉ số đánh giá qua Cross-Validation.....	7
4.3. Kết quả trên tập test.....	8
5. Tài liệu tham khảo.....	8

1. Tổng quan.

1.1. Thông tin các thành viên và tự đánh giá.

- Thông tin các thành viên:

STT	Họ và tên	Mã số sinh viên	Mức độ hoàn thành
1	Phan Bá Đức	22120071	100%
2	Nguyễn Bá Duy	22120078	100%
3	Đặng Duy Lâm	221200182	100%

- Tự đánh giá mức độ hoàn thành:

STT	Vấn Đề	Đánh giá
1	Tìm hiểu về dữ liệu, đặt vấn đề và tìm giải pháp tương ứng.	60%
2	Phát triển và huấn luyện mô hình	20%
3	Đánh giá mô hình và lựa chọn ra mô hình phù hợp nhất.	20%
4	Tổng quát	100%

1.2. Tóm tắt bài toán.

Bài toán đặt ra trong cuộc thi yêu cầu xây dựng một mô hình học máy nhằm nhận diện âm thanh đặc trưng của loài gà tây dựa trên tập các đặc trưng âm thanh đã được trích xuất sẵn. Dựa vào nhãn của tập dữ liệu **is_turkey**, đây là một bài toán phân loại nhị phân, trong đó mỗi mẫu âm thanh cần được dự đoán là *có* hoặc *không* thuộc về gà tây.

Dữ liệu được cung cấp bao gồm các đặc trưng sau:

vid_id	Video ID liên quan đến mẫu dữ liệu này
audio_embedding	Đặc trưng âm thanh theo từng frame, giảm chiều xuống còn 128 chiều bằng VGGish
start_time_seconds_youtube_clip	Thời điểm bắt đầu của đoạn audio trong video YouTube (tính bằng giây)
end_time_seconds_youtube_clip	Thời điểm kết thúc của đoạn audio trong video YouTube (tính bằng giây)
is_turkey	Nhãn mục tiêu: 1 nếu đoạn audio chứa tiếng gà tây, 0 nếu không

1.3. Ý tưởng giải quyết.

1.3.1. Tiền xử lý.

Trong bài toán này, hai thuộc tính chính được giữ lại để huấn luyện mô hình là *audio_embedding* (đặc trưng âm thanh) và *is_turkey* (nhãn phân loại). Các thuộc tính khác được loại bỏ vì không đóng góp nhiều thông tin cho quá trình học.

Tuy nhiên, một vấn đề phát sinh từ thuộc tính *audio_embedding* là nó có dạng ba chiều với kích thước (số mẫu, số frame, 128), trong khi nhãn *is_turkey* chỉ có kích thước (số mẫu, 1). Ngoài ra, số lượng frame không giống nhau giữa các mẫu, dẫn đến việc không thể xử lý dữ liệu theo cách thông thường. Do đó, nhóm đưa ra hướng giải quyết như sau:

- Mỗi mẫu với kích thước (frame, 128) được làm phẳng thành một vector một chiều có kích thước (frame $\times$ 128).
- Do số frame ở mỗi mẫu là khác nhau, cần thêm padding 0 để tất cả các mẫu có cùng số chiều, đảm bảo dữ liệu có thể đưa vào mô hình.

Sau khi xử lý xong, số chiều của dữ liệu trở nên rất lớn, dễ gây ra overfitting và tốn nhiều tài nguyên tính toán. Vì vậy, nhóm sẽ dùng thuật toán PCA để giảm chiều mà không mất quá nhiều thông tin của dữ liệu. Việc chọn số chiều giữ lại được thực hiện dựa trên việc quan sát biểu đồ phương sai để cân đối giữa việc giữ thông tin và giảm độ phức tạp.

1.3.2. Xây dựng mô hình và đánh giá.

Tập dữ liệu gồm 1195 mẫu – số lượng khá nhỏ, vì vậy, nhóm sẽ dùng Cross Validation để đánh giá mô hình chính xác hơn, tránh phụ thuộc vào cách chia dữ liệu ngẫu nhiên.


Nhãn của dữ liệu có hai lớp: 704 mẫu thuộc lớp 0 và 491 mẫu thuộc lớp 1. Sự chênh lệch này không quá đáng kể nên không cần thiết phải dùng các phương pháp cân bằng lại như oversampling hay undersampling.

Cuối cùng, nhóm quyết định sẽ kết hợp Grid Search với Cross Validation để tìm ra các siêu tham số tối ưu. Tiêu chí chính dùng để đánh giá là độ chính xác (accuracy), ngoài ra có thể xem thêm F1-score nếu cần cân nhắc kỹ hơn giữa precision và recall.

2. Tiền xử lý dữ liệu.

Như đã đề cập ở trên, nhóm em sẽ dùng tiền xử lý bằng cách flatten các embedding, sau đó thêm padding để các sample có số chiều giống nhau. Ở đây nhóm em thống nhất kích thước của padding là 1280, nghĩa là các vector có kích thước bé hơn 1280 sẽ được thêm các số 0 ở đầu sao cho đủ 1280 phần tử.

Để chọn số chiều để giữ lại, nhóm em sẽ thực hiện tính xem số lượng thành phần chính (số chiều) sao cho tổng phương sai giữ lại được lớn hơn hoặc bằng $x\%$ (với $x \in [0.5, 0.55, 0.6, \dots, 0.85, 1]$).



Thông qua trực quan ở trên, chúng em chọn giữ lại ~87% thông tin của dữ liệu, với số chiều là 340.

3. Huấn luyện mô hình.

Để đánh giá hiệu quả của các mô hình học máy khác nhau trên bài toán này, nhóm đã triển khai bốn thuật toán bao gồm: **Random Forest**, **Support Vector Machine (SVM)**, **Logistic Regression**, và **Decision Tree**.

Việc tìm kiếm các siêu tham số tối ưu được thực hiện bằng kỹ thuật Grid Search kết hợp với Cross Validation (k-fold với $k = 5$) và được đánh giá chính với độ chính xác (accuracy) trên tập huấn luyện được chia trong quá trình Cross Validation. Kết quả như sau:

Mô hình	Accuracy	Thời gian huấn luyện (giây)	Bộ nhớ tiêu thụ (Mb)
Logistic Regression	0.9425	0.53	4.00
Random Forest	0.9404	32.62	539.27
SVM	0.9393	8.83	10.99
Decision Tree	0.9226	3.79	~0

Nhận xét:

- Logistic Regression đạt độ chính xác cao nhất, đồng thời có thời gian huấn luyện nhanh nhất. Việc tiêu thụ bộ nhớ cũng cực kì ít (4.00 Mb). Điều này cho thấy mô hình tuyến tính vẫn hoạt động rất hiệu quả trong bài toán này.
- Random Forest cũng đạt kết quả rất cao, tuy nhiên mất nhiều thời gian huấn luyện hơn đáng kể do số lượng cây và độ sâu được thử nghiệm. Hơn nữa, lượng bộ nhớ đã tiêu thụ là quá lớn 539.27 Mb.
- SVM đạt độ chính xác thấp hơn nhưng không đáng kể, nhưng cần nhiều thời gian hơn so với Logistic Regression.
- Decision Tree tuy có độ chính xác thấp hơn các mô hình khác nhưng vẫn cho kết quả tốt, huấn luyện nhanh và tốn ít bộ nhớ.

Kết luận: Dựa theo đánh giá trên, Random Forest và Logistic Regression cho ra kết quả tốt gần như nhau. Nhưng đổi lại Logistic Regression có thời gian chạy nhanh hơn gần như 60 lần so với Random Forest. Ngoài ra lượng tiêu tốn bộ nhớ là cực kì lớn so với Logistic Regression.


➔ Do đó mô hình mà chúng em chọn là **Logistic Regression**.

4. Đánh giá mô hình

Sau khi hoàn tất bước huấn luyện và lựa chọn siêu tham số bằng Grid Search kết hợp Cross Validation, mô hình Logistic Regression được chọn để đánh giá cuối cùng vì đạt độ chính xác cao nhất (94.25%) và có thời gian huấn luyện nhanh nhất, lượng bộ nhớ tiêu thụ cực kì nhỏ 4Mb.

Bây giờ, nhóm sẽ xem performance của mô hình trên tập validation để đưa ra đánh giá cuối cùng (nếu điều này không tốt sẽ xem lại quá trình xử lý), thông qua kĩ thuật cross validation.

4.1. Ma trận nhầm lẫn trên tập validation



Phân tích:


- True Negative (TN) = 138: Mô hình dự đoán chính xác 138 mẫu không phải là âm thanh gà tây.
- False Positive (FP) = 3: Mô hình nhầm 3 mẫu không phải là gà tây thành gà tây.
- False Negative (FN) = 10: Mô hình bỏ sót 10 mẫu gà tây, dự đoán sai là không phải gà tây.
- True Positive (TP) = 88: Mô hình dự đoán đúng 88 mẫu là gà tây.

Các chỉ số rút ra từ ma trận:

- Accuracy = $(TP + TN) / \text{Tổng} = (88 + 138) / (138 + 3 + 10 + 88) \approx 94.56\%$
- Precision (class 1) = $TP / (TP + FP) = 88 / (88 + 3) \approx 96.7\%$
- Recall (class 1) = $TP / (TP + FN) = 88 / (88 + 10) \approx 89.8\%$
- F1-score $\approx 93.1\%$

→ Mô hình hoạt động tốt khi phát hiện các âm thanh không phải gà tây (precision cao). Tuy nhiên, mô hình lại bỏ sót một số âm thanh là gà tây (recall < precision), dẫn đến số False Negative cao hơn False Positive.

4.2. Phân bố các chỉ số đánh giá qua Cross-Validation



Biểu đồ boxplot thể hiện sự phân bố của ba chỉ số quan trọng: Precision, Recall, và F1-score qua các fold của quá trình cross-validation.

Nhận xét từng chỉ số:

- Precision:
 - Giá trị trung bình nằm trong khoảng 0.94 – 0.97, dao động không lớn. Phân bố tập trung ở 0.97 (quan sát đường màu đỏ).
 - Điều này cho thấy mô hình hiếm khi nhầm lẫn các mẫu không phải gà tây thành gà tây.
- Recall:
 - Dao động trong khoảng 0.85 – 0.91. Có một vài fold có recall thấp (~0.85), cho thấy mô hình đôi khi bỏ sót âm thanh là gà tây (false negatives). Phân bố tập trung ở 0.908.
- F1-score:
 - Là chỉ số trung bình điều hòa giữa precision và recall.
 - Tập trung quanh 0.91 – 0.94 và phân bố tập trung ở 0.937, cho thấy mô hình đạt hiệu quả tổng thể tốt và ổn định giữa hai chỉ số kia.
- **Tổng thể**, mô hình Logistic Regression không chỉ đạt kết quả cao về mặt chính xác, mà còn ổn định và ít biến động giữa các fold.


Kết luận:

- Mô hình đã khá tốt, không gặp các vấn đề khác như overfitting, high variance across folds (biến động mạnh trên tập validate).. nhóm chúng em quyết định sẽ chọn mô hình này, để đi thi trên tập test.

4.3. Kết quả trên tập test

Cuối cùng, nhóm sẽ thực hiện dự đoán trên tập test. Kết quả sau khi submit của nhóm:

22120071_22120078_22120182



0.990457

2

5h

5. Tài liệu tham khảo

- [1] [Online]. Available: <https://machinelearningcoban.com/2017/06/15/pca/>.
- [2] [Online]. Available: <https://machinelearningcoban.com/2017/04/09/smv/>.
- [3] [Online]. Available: <https://scikit-learn.org/0.21/documentation.html>.