

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN MÔN HỌC MÁY
Phase 3

Sinh viên thực hiện:

Phan Bá Đức - 22120071

Nguyễn Bá Duy - 22120078

Đặng Duy Lâm - 22120182

Giang viên hướng dẫn:

TS. Bùi Duy Đăng

ThS. Nguyễn Thanh Tình

TP. Hồ Chí Minh, tháng 6 năm 2025.

Mục lục

Mục lục.....	1
1. Tổng quan.....	2
1.1. Thông tin các thành viên và tự đánh giá.....	2
1.2. Tóm tắt bài toán.....	2
1.3. Model Development	3
1.3.1. Mô hình CNN.....	3
1.3.2. Mô hình Transformer Custom.....	3
2. Model Evaluation.....	4
2.1. Mô hình CNN	4
2.1.1. Đánh giá mô hình	4
2.1.2. Phân tích điểm mạnh và điểm yếu của mô hình.....	7
2.2. Mô hình Tranformer Custom.....	7
2.2.1. Đánh giá mô hình	7
2.2.2. Phân tích điểm mạnh và điểm yếu của mô hình.....	9
3. Tài liệu tham khảo.....	10

1. Tổng quan

1.1. Thông tin các thành viên và tự đánh giá.

Thông tin các thành viên:

STT	Họ và tên	Mã số sinh viên	Mức độ hoàn thành
1	Phan Bá Đức	22120071	100%
2	Nguyễn Bá Duy	22120078	100%
3	Đặng Duy Lâm	22120182	100%

Tự đánh giá mức độ hoàn thành:

STT	Vấn Đề	Đánh giá
1	Tìm hiểu về dữ liệu, đặt vấn đề và tìm giải pháp tương ứng.	60%
2	Phát triển và huấn luyện mô hình	17%
3	Đánh giá mô hình và lựa chọn ra mô hình phù hợp nhất.	20%
4	Tổng quát	97%

1.2. Tóm tắt bài toán

Bài toán đặt ra trong cuộc thi yêu cầu xây dựng một mô hình học máy nhằm nhận diện âm thanh đặc trưng của loài gà tây dựa trên tập các đặc trưng âm thanh đã được trích xuất sẵn. Dựa vào nhãn của tập dữ liệu **is_turkey**, đây là một bài toán phân loại nhị phân, trong đó mỗi mẫu âm thanh cần được dự đoán là *có* hoặc *không* thuộc về gà tây.

Dữ liệu được cung cấp bao gồm các đặc trưng sau:

vid_id	Video ID liên quan đến mẫu dữ liệu này
audio_embedding	Đặc trưng âm thanh theo từng frame, giảm chiều xuống còn 128 chiều bằng VGGish

start_time_seconds_youtube_clip	Thời điểm bắt đầu của đoạn audio trong video YouTube (tính bằng giây)
end_time_seconds_youtube_clip	Thời điểm kết thúc của đoạn audio trong video YouTube (tính bằng giây)
is_turkey	Nhãn mục tiêu: 1 nếu đoạn audio chứa tiếng gà tây, 0 nếu không

1.3. Model Development

1.3.1. Mô hình CNN

- Phân tích dữ liệu hiện có:


- Dữ liệu đầu vào tập trung vào thuộc tính audio embedding với kích thước $[n_sample, frame, 128]$, và nhãn is turkey $\in \{0, 1\}$.

- Quy trình xử lý dữ liệu:

Đọc dữ liệu $\rightarrow$ Chuẩn hoá audio embedding $\rightarrow$ Chia dữ liệu $\rightarrow$ Xử lý mất cân bằng.

- Phân tích và lựa chọn mô hình:

- Kiến trúc:




- Lý do:

- Sử dụng các Block gồm Convolution Layer 1D, Max Pooling 1D **dùng để trích xuất đặc trưng nổi bật**, sau đó dữ liệu được đưa đến **Global Pooling dùng để tổng hợp các đặc trưng**.
- Đưa vào Full Connected layer, kèm dropout để tránh overfitting.
- Ngoài ra Dropout và regularization L2 (được thêm ở Full connected ở cuối hidden layer) giúp mô hình tránh học quá mức các chi tiết nhiễu, đồng thời **tổng quát hóa tốt** hơn khi gặp dữ liệu mới.

1.3.2. Mô hình Transformer Custom

- Phân tích và lựa chọn mô hình:

- Kiến trúc mô hình:



○ Lý do:


- Với Transformer thuần túy, mô hình sẽ coi từng frame (trong audio embedding) là những phần độc lập , không có thứ tự rõ ràng hay ngữ cảnh tạm thời giữa các frame, làm giảm hiệu quả trong các bài toán thời gian.
- Với Tranformer được custom ở trên: đầu vào được tích hợp với **positional encoding** giúp mô hình học được đặc trưng ngữ cảnh theo chiều thời gian mà không cần tái cấu trúc dữ liệu.
- **Encoder** sử dụng cơ chế self-attention để nắm bắt mối liên hệ toàn cục (global dependencies) giữa các frame trong một đoạn âm thanh. Phần Decoder trong trường hợp này là không cần thiết.

2. Model Evaluation

2.1. Mô hình CNN

2.1.1. Đánh giá mô hình


- Đánh giá mô hình thông qua việc sử dụng K-Fold:



Hình 1: Thể hiện thông số đánh giá của mô hình.

- Phân tích:

- Hiệu suất dự đoán:
 - F1-score trung bình (0.9616) và accuracy trung bình (0.9618) cho thấy mô hình có hiệu suất rất cao và ổn định trên tập validation qua các fold. Các giá trị này gần nhau, phản ánh sự cân bằng tốt giữa độ chính xác và khả năng phát hiện lớp thiểu số ($is_turkey=1$), nhờ vào việc áp dụng SMOTE và class weights.
 - Biểu đồ F1-score và Accuracy theo fold cho thấy xu hướng tăng dần từ fold 1, fold 2 đến fold 5, với fold 5 đạt đỉnh (F1-score ~ 0.9677 , Accuracy ~ 0.9689). Điều này có thể do sự phân bố dữ liệu sau SMOTE hoặc hiệu ứng early stopping trong các fold sau.
- Thời gian huấn luyện:
 - Thời gian trung bình mỗi fold là 11.16 giây, với dao động từ khoảng 10 giây (fold 5) đến 14 giây (fold 1), theo biểu đồ. Sự giảm dần thời gian có thể liên quan đến early stopping (dừng sớm sau 3 epoch không cải thiện), giúp mô hình hội tụ nhanh hơn ở các fold sau.
- Kích thước mô hình:
 - Kích thước trung bình của mô hình là 2.11 MB
 - Kích thước này rất nhỏ, phù hợp cho triển khai trên thiết bị có tài nguyên hạn chế (như edge devices).
- Độ ổn định:
 - Hiệu suất dao động nhẹ giữa các fold, cho thấy mô hình có độ ổn định tốt. - - Sự khác biệt có thể xuất phát từ cách chia dữ liệu stratified và ảnh hưởng của SMOTE.
 - Thời gian huấn luyện và kích thước mô hình cũng ổn định, với biến thiên nhỏ, phản ánh tính nhất quán trong quá trình huấn luyện.
- Đánh giá mô hình trên tập validation:



Hình 2 : Confusion Matrix và ROC Curve trên mô hình CNN.

- Phân tích:

- Hiệu suất tổng quan:
 - Mô hình đạt accuracy 0.9498 khá cao
 - F1-score 0.9388 và AUC-ROC 0.9481 là các chỉ số rất tốt, phản ánh khả năng phân loại cân bằng giữa lớp `is_turkey=0` và `is_turkey=1`.
- Confusion Matrix:
 - True Negatives (135) và True Positives (92) chiếm phần lớn, cho thấy mô hình dự đoán chính xác trên cả hai lớp.
 - False Positives (6) và False Negatives (6) là số lượng lỗi nhỏ, tương ứng với tỷ lệ lỗi khoảng 2.5% (6/239), rất thấp.
 - Tỷ lệ FP và FN gần bằng nhau (6 và 6) cho thấy mô hình không thiên lệch rõ rệt về lớp nào, phù hợp với dữ liệu đã được cân bằng bằng SMOTE.
- Điểm yếu tiềm ẩn:
 - Sai sót nhỏ trong phân loại: Dù số lượng FP và FN thấp, 6 mẫu bị phân loại sai (tổng 12/239, ~5%) có thể là do nhiễu trong dữ liệu âm thanh (`audio_embedding`) hoặc hạn chế của mô hình CNN trong việc học các đặc trưng phức tạp.
 - Hiệu suất trên tập test thấp hơn validation: So với F1-score trung bình cross-validation (0.9616) và accuracy (0.9618), các chỉ số trên tập test (0.9388 và 0.9498) thấp hơn khoảng 2-3%. Điều này có thể chỉ ra hiện tượng overfitting nhẹ.
- ROC và AUC-ROC:

- AUC-ROC 0.9481 là rất cao, gần với giá trị lý tưởng (1.0), cho thấy mô hình có khả năng phân biệt tốt giữa hai lớp.

2.1.2. Phân tích điểm mạnh và điểm yếu của mô hình.

- Điểm mạnh:
 - Hiệu suất cao trên validation:
 - F1-score trung bình: 0.9616
 - Accuracy trung bình: 0.961
 - Mô hình học tốt đặc trưng âm thanh với hiệu quả cao.
 - Cân bằng giữa Precision và Recall:
 - Nhờ vào kỹ thuật SMOTE và class weights, mô hình tránh được bias về một lớp cụ thể.
 - Tốc độ huấn luyện nhanh và ổn định:
 - Trung bình mỗi fold chỉ mất khoảng 11.16 giây, có xu hướng giảm dần nhờ early stopping.
 - Kích thước mô hình nhỏ (~2.11MB):
 - Phù hợp để triển khai trên các thiết bị tài nguyên hạn chế như thiết bị IoT hoặc edge computing.
 - Độ ổn định cao giữa các fold:
 - Hiệu suất không biến động lớn → đáng tin cậy và nhất quán.
 - Hiệu suất trên tập test tốt:
 - Accuracy: 94.98%
 - F1-score: 93.88%
 - AUC-ROC: 0.9481 → năng lực phân biệt 2 lớp rất mạnh.
- Điểm yếu:
 - Hiện tượng overfitting nhẹ:
 - Hiệu suất trên test thấp hơn ~2–3% so với validation.

2.2. Mô hình Tranformer Custom

2.2.1. Đánh giá mô hình

- Đánh giá mô hình:
 - Mô hình sau khi train với 5-Fold, mang lại Accuracy trung bình: 0.9634 và F1 trung bình: 0.9543.


- Đánh giá mô hình tốt nhất trên tập validation:

Fold	Accuracy	Precision	Recall	F1-score
1	0.9121	0.8807	0.9231	0.9014
2	0.9247	0.9216	0.9038	0.9126
3	0.9163	0.8962	0.9135	0.9048
4	0.9038	0.8649	0.9231	0.8930
5	0.9289	0.9579	0.8750	0.9146

- Phân tích:

- Mô hình cho kết quả nhất quán và tốt trên tập test, với F1 Score dao động từ 0.8930 đến 0.9146, thể hiện khả năng phân loại ổn định và đáng tin cậy.
- Trung bình Accuracy đạt khoảng 91.8%, là mức cao trong một bài toán phân loại nhị phân dựa trên embedding âm thanh.
- Precision và Recall đều duy trì ở mức cao và tương đối cân bằng giữa các fold, cho thấy mô hình không bị lệch về một lớp cụ thể, điều này rất quan trọng trong các bài toán nhận dạng thực tế.
- Fold 2 và Fold 5 đạt kết quả test cao nhất ($F1 = 0.9126$ và 0.9146), cho thấy các tập huấn luyện tương ứng với hai fold này có thể đại diện tốt hơn cho phân bố dữ liệu thực tế hoặc mô hình học được đặc trưng âm thanh hiệu quả hơn trên những fold đó.

- Đánh giá mô hình thông qua Confusion Metric và ROC Curve



Hình 3 : Confusion Matrix và ROC Curve trên mô hình Tranformer.

- Phân tích:

- Hiệu suất dự đoán cho nhãn 0 khá tốt với 131 mẫu được dự đoán đúng (True Negative) và chỉ 4 mẫu bị nhầm (False Positive).
- Đối với nhãn 1, có 94 mẫu được dự đoán đúng (True Positive) nhưng 13 mẫu bị nhầm (False Negative).
- Tổng thể, mô hình có độ chính xác cao, đặc biệt với nhãn 0, nhưng có một số nhầm lẫn với nhãn 1.
- Đường cong ROC:
 - Diện tích dưới đường cong (AUC) là 0.97, cho thấy mô hình có khả năng phân loại rất tốt giữa các lớp.
 - Đường cong nằm xa đường chéo (random guess), chứng tỏ mô hình có hiệu quả cao trong việc phân biệt nhãn dương và nhãn âm.
 - Tổng kết: Mô hình hoạt động tốt với AUC cao và ma trận nhầm lẫn cho thấy độ chính xác đáng kể, dù có một số lỗi nhỏ cần cải thiện, đặc biệt với nhãn 1.

2.2.2. Phân tích điểm mạnh và điểm yếu của mô hình

- Điểm mạnh:

- Hiệu suất cao và đồng đều giữa các fold:
 - Accuracy trung bình: 96.34%
 - F1-score trung bình: 95.43%
 - Mô hình thể hiện tính tổng quát hóa tốt.
- Kết quả test nhất quán và đáng tin cậy:
 - F1-score dao động từ 0.8930 đến 0.9146, Accuracy khoảng 91.8%.
 - Không bị thiên lệch lớp nhờ balance tốt giữa Precision và Recall.
- AUC cao (~0.97):
 - ROC curve cho thấy khả năng phân biệt giữa hai lớp rất rõ ràng, vượt trội hơn cả CNN.
- Tận dụng tốt mối liên hệ giữa các frame âm thanh:
 - Kiến trúc Tranformer custom giúp mô hình hiểu ngữ cảnh âm thanh liên tục tốt hơn Transformer thuần túy.

- Điểm yếu:

- Dự đoán nhãn 1 (gà tây) còn hạn chế:

- False Negative cao hơn (13 FN so với 4 FP) → mô hình chưa thực sự nhạy với các trường hợp gà tây "mò" hoặc bị che khuất tiếng.
- Hiệu suất test thấp hơn validation
- Phức tạp và tốn tài nguyên hơn CNN:
 - Mặc dù không nêu rõ thời gian và kích thước mô hình, Transformer thường đòi hỏi nhiều tài nguyên hơn trong inference và huấn luyện.

3. Tài liệu tham khảo

- [1] [Online]. Available: <https://machinelearningcoban.com/2017/06/15/pca/>.
- [2] [Online]. Available: <https://machinelearningcoban.com/2017/04/09/smv/>.
- [3] [Online]. Available: <https://scikit-learn.org/0.21/documentation.html>.
- [4] "SMOTE," [Online]. Available: https://imbalanced-learn.org/stable/references/generated/imblearn.over_sampling.SMOTE.html.
- [5] "compute_class_weight," [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.utils.class_weight.compute_class_weight.html.